SKKAI

RL Study

LECTURE 07

Synthetic Data & Modern Post-Training

목차

01 Synthetic Data & KD

합성 데이터와 지식 증류

02 Offline Knowledge Distillation

Teacher의 데이터로 배우기와 그 한계

03 On-policy Distillation

Student가 직접 생성하며 배우기

04 AI Feedback & Rubric

AI가 평가자가 되는 방법

01

Synthetic Data & KD

합성 데이터와 지식 증류

Synthetic Data in Modern Post-Training

AI가 데이터를 만들고, 가르치고, 평가한다

합성 데이터(Synthetic Data)는 생성 과정의 일부라도 다른 AI 모델이 관여한 학습 데이터다.

오늘날 Post-training에서 AI는 크게 세 가지 역할을 맡는다.



AI가 생성한 데이터로 다른 AI를 어떻게 개선할 수 있는가?

Synthetic Data Across the Training Pipeline

합성 데이터의 활용

합성 데이터는 여러 학습 알고리즘에 **데이터를 공급하는 기술**이다.



학습 단계	합성 데이터의 역할	AI가 만드는 것
Prompt generation	시드 예시로부터 새로운 질문과 작업을 생성	프롬프트
SFT	프롬프트에 대한 모범 응답을 생성	응답 (Completion)
RLHF / DPO	두 응답 중 더 나은 쪽을 판정해 선호 데이터 생성	선호 레이블
RLVR	정답을 검증해 보상을 생성	검증 결과 · 보상
Data curation	오류를 제거하고 품질을 필터링	유지 / 제거 판정

Can Synthetic Data Replace Human Data?

장점과 위험, 그리고 품질 관리

합성 데이터는 싸고 빠르지만, 검증 없이 반복 학습하면 문제가 생길 수 있다.

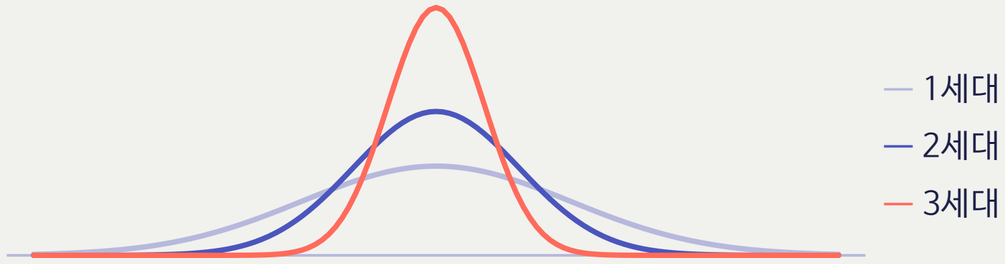
장점

- 저비용 · 대규모 데이터 생성
- 빠른 실험 반복
- 고성능 Teacher의 능력 이전

잠재적인 문제

- 오류와 편향의 반복 학습
- 데이터 다양성 감소
- Model Collapse 가능성

검증 없는 재귀 학습을 진행한다면...



세대를 거칠수록 분포가 좁아지고 tail부터 사라진다

해결 방법

- Human / Real Data 혼합
- Diverse Teachers 활용
- Deduplication
- Quality Filtering

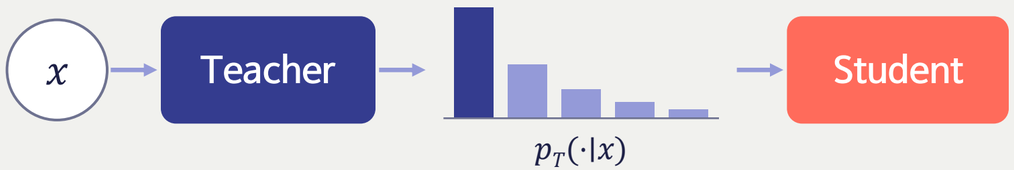
Two Meanings of Distillation

무엇을 전달하는가: 확률분포 vs. 생성 텍스트

Knowledge Distillation(KD)은 Teacher의 지식이나 행동을 Student로 옮기는 방법이다.

Distribution-based KD

전통적 KD

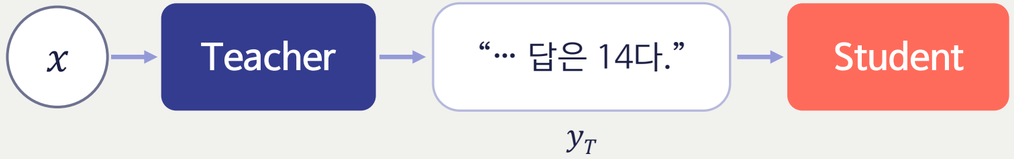


$$D_{\mathrm{KL}}(p_T \parallel p_S)$$

- Teacher의 출력 확률분포 전체를 Student가 모방한다.
- Soft Label: 정답 외 후보 토큰의 확률까지 전달한다. 각 class별 확률까지 학습하도록 한다.

Response-based KD

넓은 의미의 KD



$$-\log p_S(y_T \mid x)$$

- Teacher가 생성한 응답을 정답으로 삼아 SFT한다.
- 생성된 텍스트만 있으면 되므로 API 출력으로도 가능하다. 즉 Teacher의 확률분포가 없어도 학습할 수 있다.

02

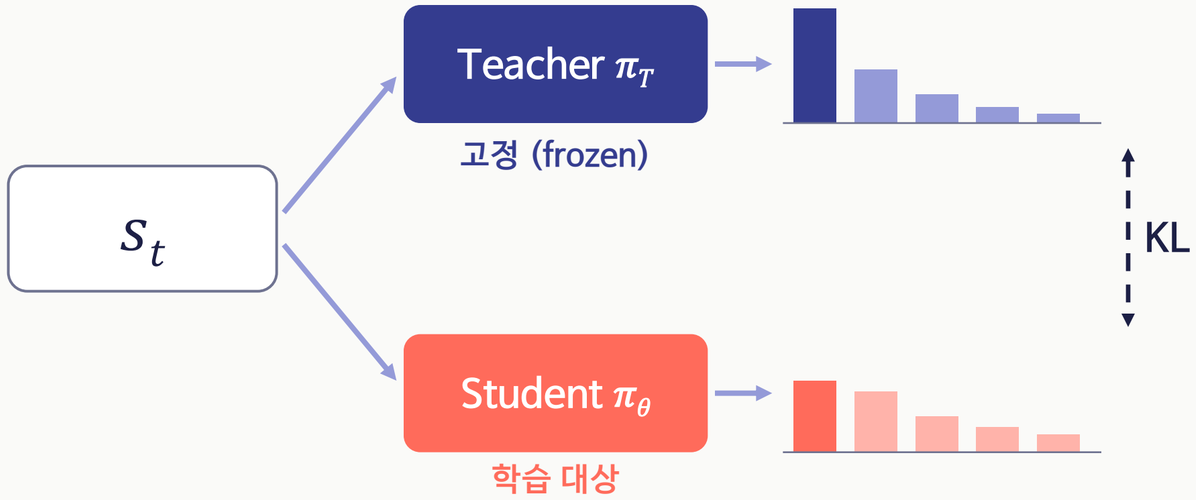
Offline Knowledge Distillation

Teacher의 데이터로 배우기와 그 한계

Classic Knowledge Distillation

Teacher의 토큰 확률분포 전체를 학습한다

Teacher와 Student가 같은 문맥을 입력받고, Student는 Teacher의 다음 토큰 확률분포를 따라가도록 학습한다.



목적함수

$$\mathcal{L}_{\mathrm{KD}} = \sum_{t=1}^{L} D_{\mathrm{KL}}\big(\pi_T(\cdot \mid s_t) \parallel \pi_\theta(\cdot \mid s_t)\big)$$

- π_T 고정된 Teacher
- π_θ 학습 대상 Student
- s_t 현재 토큰을 예측할 때 쓰는 문맥

Soft Label 정답 토큰 하나(one-hot)가 아니라 다른 후보 토큰들의 확률까지 전달한다.

Temperature를 높이면 분포가 부드러워져 후보 토큰 사이의 관계가 더 잘 드러난다.

Relation between Sequence-level KD and SFT

Teacher 응답으로 하는 SFT는 Forward KL 최소화와 연결된다

Teacher가 생성한 응답 u를 정답으로 삼아 Student를 학습한다.

$$u \sim \pi_T(\cdot \mid s)$$

← Teacher의 분포에서 응답 u를 샘플링한다

$$\mathcal{L}_{\text{SEQ-KD}} = -\sum_t \log \pi_\theta(u_t \mid s, u_{<t})$$

← 샘플링한 응답으로 Student를 SFT한다 (NLL)

$$H(\pi_T, \pi_\theta) = H(\pi_T) + D_{\text{KL}}(\pi_T \parallel \pi_\theta)$$

← 샘플 평균은 Cross-Entropy이며, 이렇게 분해된다

$$\min_\theta H(\pi_T, \pi_\theta) \equiv \min_\theta D_{\text{KL}}(\pi_T \parallel \pi_\theta)$$

← Teacher가 고정이므로 $H(\pi_T)$는 θ에 대해 상수다

→ Teacher 데이터에 대한 SFT는 기대값 관점에서 Forward KL 최소화와 연결된다.

단, Beam Search로 대표 응답 하나만 고르면 Teacher의 전체 분포가 아니라 그 응답의 NLL을 최적화하게 된다.

The Problem: Exposure Bias

학습할 때와 추론할 때 보는 문맥이 다르다

Offline KD는 학습 때 Teacher가 만든 문맥을 보지만, 추론 때는 **Student 자신이 만든 문맥**을 이어 써야 한다.

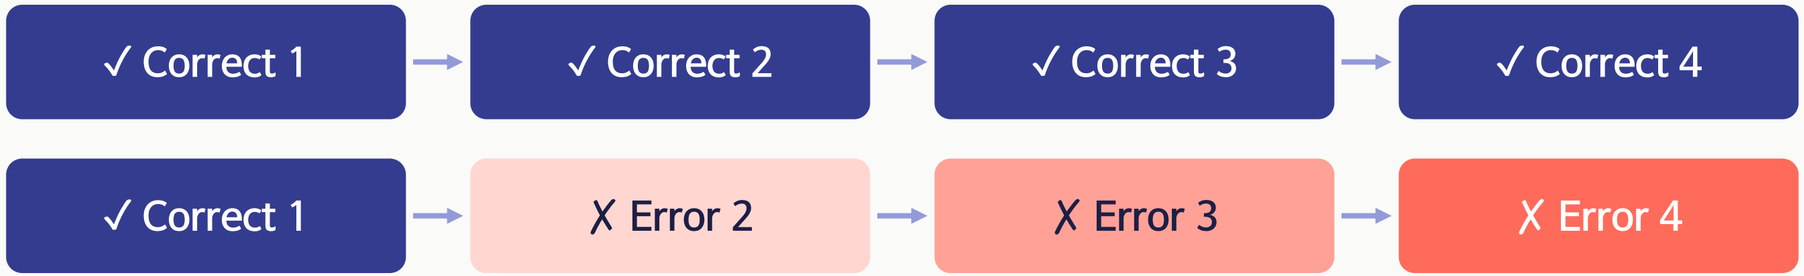
이를 Training–Inference Mismatch라고 한다.

학습 (Teacher 문맥)

$u \sim \pi_T,\ s_t = (s, u_{<t})$

추론 (Student 문맥)

$a \sim \pi_\theta,\ s_t = (s, a_{<t})$



Student의 작은 초기 실수가 학습 때 본 적 없는 문맥을 만들고, 이후 오류를 부른다

$$d^{\pi_T}(s_t) \neq d^{\pi_\theta}(s_t) \rightarrow \textbf{두 정책이 방문하는 상태 분포가 서로 다르다}$$

DAgger의 Compounding Error 직관

고전 모방 학습에서는 길이 L의 궤적에서 누적 손실이 $O(\epsilon L^2)$까지 커질 수 있고, Student가 방문한 상태에서 다시 지도받으면 $O(\epsilon L)$로 줄어든다.

03

On-policy Distillation

Student가 직접 생성하며 배우기

The Key Idea of On-policy Distillation

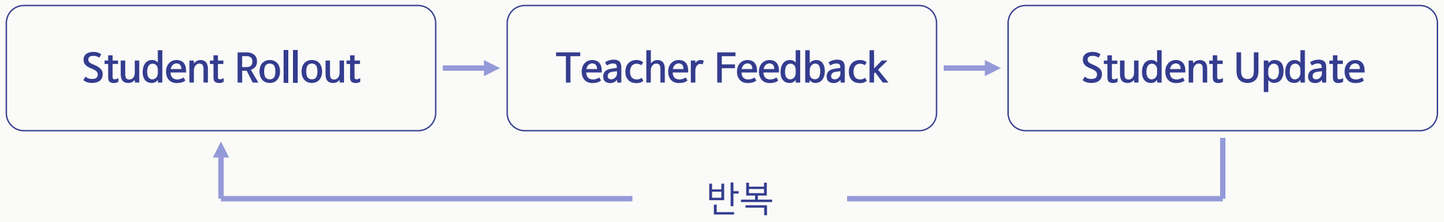
Rollout을 누가 생성하는가

Offline KD와 달리 **Student가 자신의 Rollout을 생성**하고, Teacher는 그 문맥마다 피드백을 준다.

Offline KD Teacher가 생성하고 Student가 모방하는 방식



On-policy Distillation Student가 생성하고 Teacher가 평가하는 방식



학습 흐름

1. Student가 응답을 생성한다.
2. Teacher가 Student가 방문한 각 문맥을 평가한다.
3. Student를 Teacher의 행동에 가깝게 업데이트한다.

Student가 실제로 방문하는 상태(자신의 실수 포함)에서 Teacher의 피드백을 받는다.

Objective of On-policy Distillation

Student의 문맥에서 두 분포를 비교한다

Student가 생성한 시퀀스와 각 토큰의 상태를 다음과 같이 둔다.

Student 시퀀스 $a = (a_1, \ldots, a_L), \quad a \sim \pi_\theta(\cdot \mid s)$

토큰 t의 상태 $s_t = (s, a_{<t})$

$$\mathcal{L}_{\mathrm{OPD}}(\theta) = \mathbb{E}_{s,a\sim\pi_\theta}\left[\sum_t D_{\mathrm{KL}}\big(\pi_\theta(\cdot \mid s_t) \,\|\, \pi_T(\cdot \mid s_t)\big)\right]$$

Offline KD

$u \sim \pi_T \quad D_{\mathrm{KL}}(\pi_T \,\|\, \pi_\theta)$

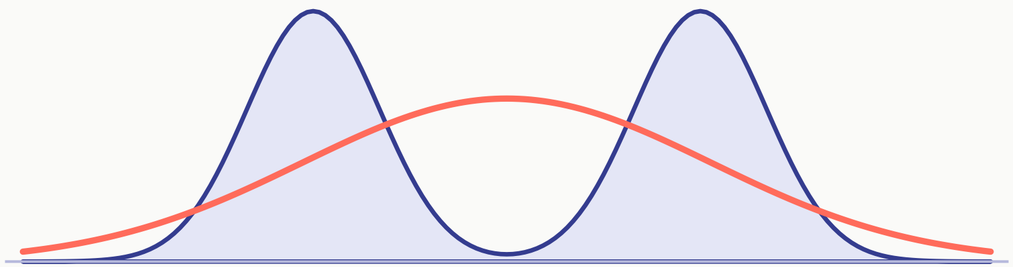
On-policy Distillation

$a \sim \pi_\theta \quad D_{\mathrm{KL}}(\pi_\theta \,\|\, \pi_T)$

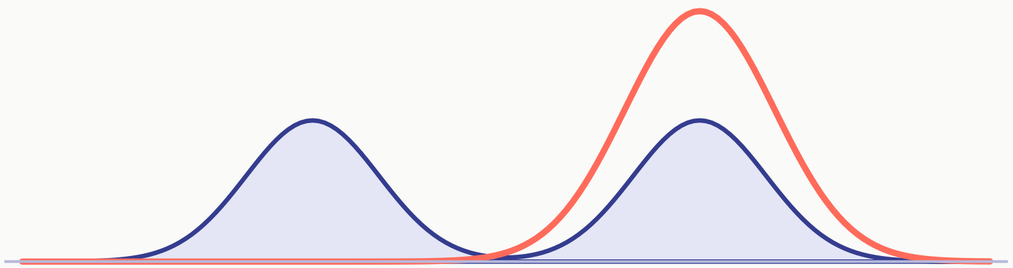
Forward KL vs. Reverse KL

분포 차이를 어느 방향으로 측정하는가

Forward KL $D_{\mathrm{KL}}(\pi_T \parallel \pi_\theta)$



Reverse KL $D_{\mathrm{KL}}(\pi_\theta \parallel \pi_T)$



—— Teacher π_T (다봉 분포)　—— Student π_θ (단봉 분포로 근사)

Mass-covering Teacher가 확률을 두는 영역을 모두 덮으려 한다

Mode-seeking Teacher가 높은 확률을 주는 영역에 집중한다

- **On-policy / Off-policy** 어느 정책이 Rollout을 생성하는가?
- **Forward / Reverse KL** 두 분포의 차이를 어느 방향으로 측정하는가?

KD as an RL Advantage

KL을 토큰 단위 학습 신호로 바꾼다

Reverse KL은 Student가 샘플링한 토큰에 대한 기대값으로 쓸 수 있다.

$$D_{\mathrm{KL}}\big(\pi_\theta(\cdot \mid s_t) \,\|\, \pi_T(\cdot \mid s_t)\big) = \mathbb{E}_{a_t \sim \pi_\theta}[\log \pi_\theta(a_t \mid s_t) - \log \pi_T(a_t \mid s_t)]$$

따라서 Student가 생성한 토큰마다 다음 신호를 정의할 수 있다.

$$A_t^{\mathrm{OPD}} = \log \pi_T(a_t \mid s_t) - \log \pi_\theta(a_t \mid s_t)$$

$A_t > 0$ Teacher가 상대적으로 더 선호하는 토큰

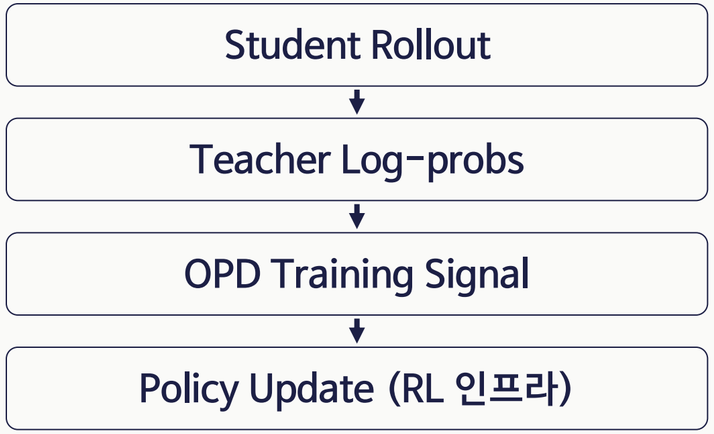
$A_t < 0$ Student가 Teacher보다 과하게 선호하는 토큰

How Does OPD Connect to PPO and GRPO?

OPD를 강화학습에 적용하기

OPD는 Teacher로부터 학습 신호를 정의하고, PPO·GRPO는 그런 신호로 정책을 업데이트하는 방법과 연결된다.

구분	PPO / GRPO	OPD
주요 관심	정책 업데이트와 Advantage 활용	Teacher의 행동을 Student에 전달
학습 신호	환경 보상, 보상 모델 등	Teacher–Student 로그 확률 차이
피드백 단위	주로 시퀀스 · 그룹 단위 보상	토큰 단위 신호 활용 가능



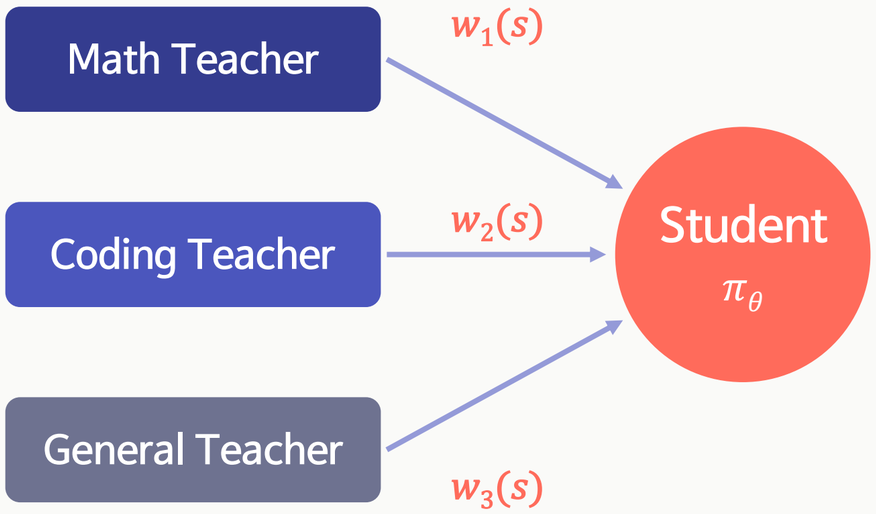
$$A_t^{\mathrm{OPD}} \neq Q(s_t, a_t) - V(s_t)$$

OPD의 로그 확률 차이는 Teacher 모방을 위한 신호이며, 일반적인 Actor–Critic의 Advantage와 반드시 같지 않다.
긴 시퀀스 전체의 Reverse KL을 정확히 미분하려면 미래 토큰의 기여까지 고려해야 한다.

Multi-teacher On-Policy Distillation

여러 전문 Teacher의 지식을 하나의 Student로

하나의 Student가 여러 전문 Teacher의 지식을 함께 배운다. Prompt마다 어떤 Teacher를 얼마나 따를지 가중치로 정한다.



$$\mathcal{L}_{\text{MOPD}} = \mathbb{E}_{s,a\sim\pi_\theta}\left[\sum_t \sum_k w_k(s)\, D_{\text{KL}}\left(\pi_\theta(\cdot|\, s_t) \;\|\; \pi_{T_k}(\cdot|\, s_t)\right)\right]$$

$$\text{where} \sum_k w_k(s) = 1$$

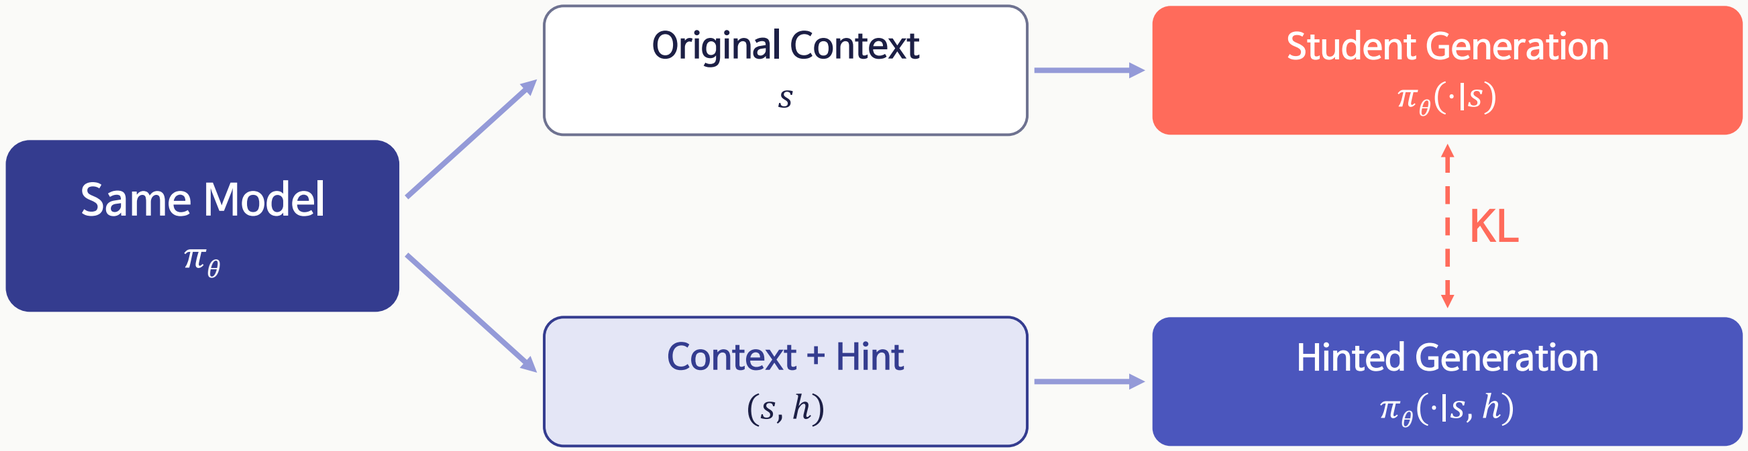
- 여러 Teacher의 전문성 활용
- Prompt별 Teacher 가중치 조절
- 단일 Student에 여러 능력 통합

On-policy Self-Distillation

더 강한 Teacher가 없다면, Hint를 가진 자신이 Teacher가 된다

Student보다 강한 Teacher가 없다면?

→ 같은 모델에 추가 정보(Privileged Information, Hint)를 주어 Teacher 역할을 맡긴다.



추론할 때는 Hint 없이 원래 문맥만 주어진다. 그래서 Hint가 있을 때의 행동을 원래 조건으로 옮겨 둔다.

04

AI Feedback & Rubric

AI가 평가자가 되는 방법

From Human Feedback to AI Feedback(RLAIF)

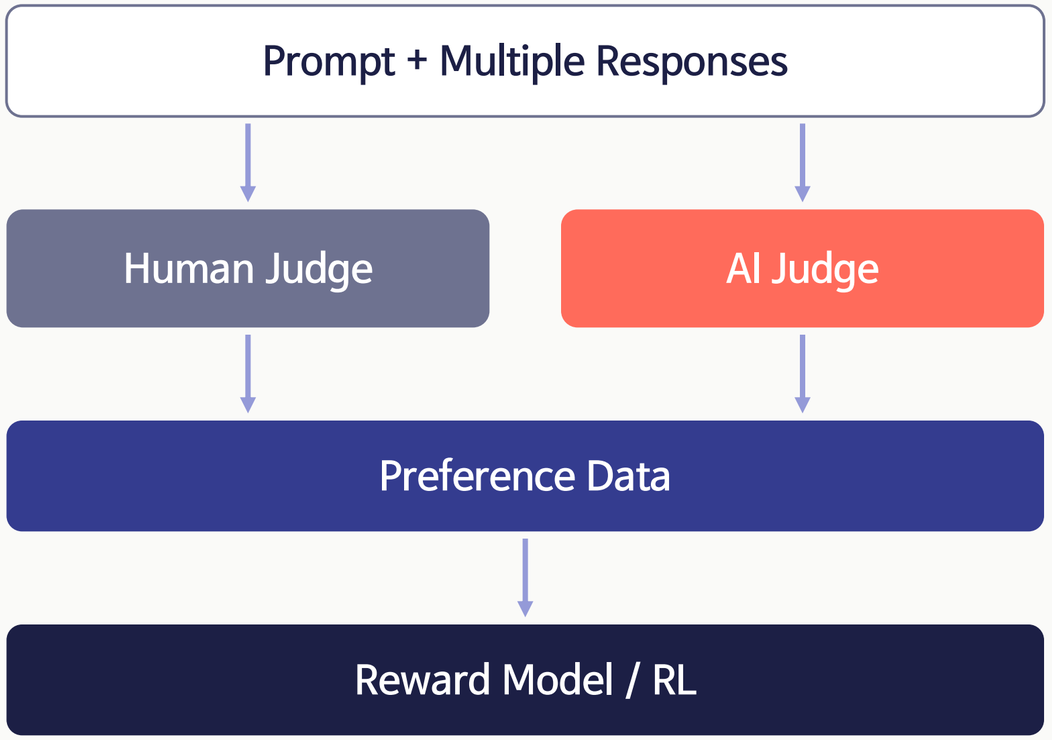
선호 데이터를 만드는 평가자를 AI로

RLAIF는 RLHF에서 사람이 맡던 선호 평가 단계를 AI로 대체하거나 확장한다.

RLHF
인간의 선호 데이터를 활용한 강화학습
High variance, low bias

RLAIF
AI가 생성한 선호 데이터를 활용한 강화학습
Low variance, high bias

- 데이터 수집 비용 감소
- 대규모 선호 평가 자동화
- 같은 평가 기준을 반복해서 적용 가능



Limitations of AI Judges

AI 평가의 품질은 어떻게 검증하는가

AI Judge는 싸고 빠르지만, 그 평가가 항상 믿을 만한 것은 아니다.

Systematic Bias

특정 응답 형식이나 표현을 과도하게 선호한다

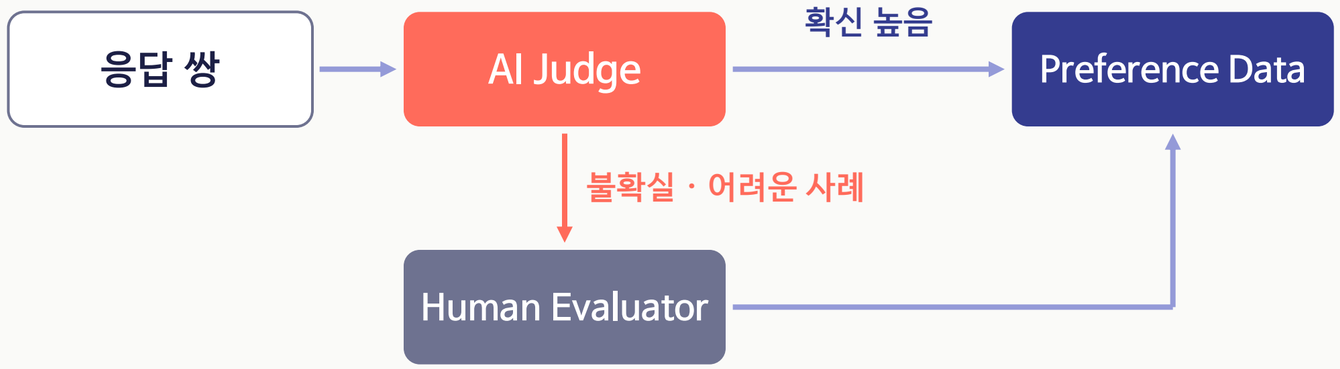
Self-preference Bias

자신이 생성한 결과에 더 높은 점수를 준다

Evaluation Inconsistency

응답 순서나 평가 프롬프트에 따라 결과가 바뀐다

Hybrid Evaluation 불확실한 사례만 사람에게 보낸다



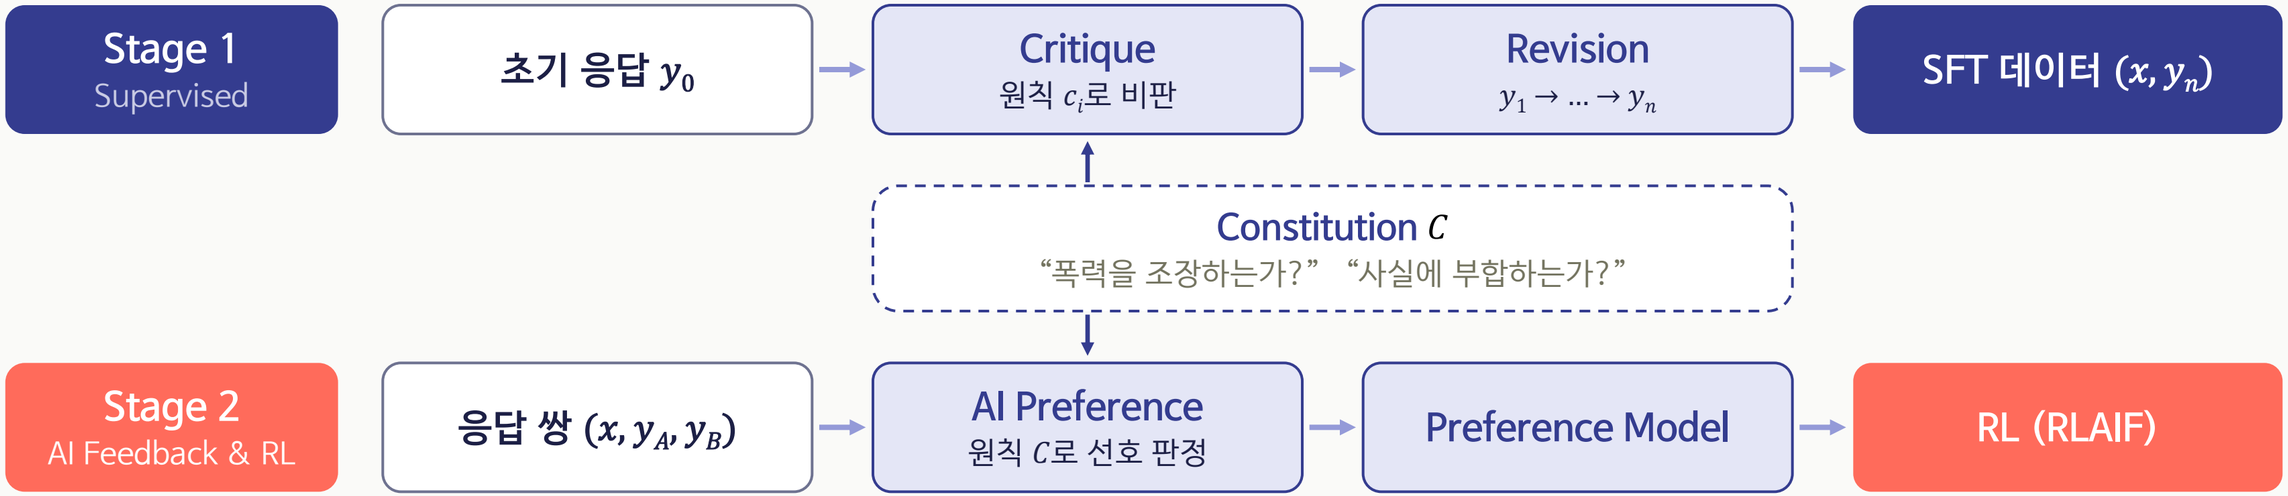
Strategies

- 인간 평가와 AI 평가의 혼합
- 어렵거나 불확실한 사례의 Human Routing
- 독립적인 기준과 평가 결과 비교
- 응답 순서 교환 등 편향 점검

Constitutional AI: Principles as Feedback

사람은 모든 답변 대신 평가 원칙을 제공한다

Constitutional AI(CAI)는 사람이 정한 원칙(Constitution) $C = \{c_1, c_2, ..., c_n\}$을 이용해 AI가 데이터를 생성하고 평가하게 하는 방법이다.



사람이 모든 답변을 평가하는 대신 **평가 원칙(Rubric)**을 제공한다.

Rubric-based Feedback

개방형 작업의 보상을 여러 평가 기준으로 분해한다

명확한 정답이 없는 작업에서 보상을 어떻게 정의할까?

→ Rubric은 응답의 품질을 여러 평가 기준으로 나누어 채점한다.

예시 Prompt

“PPO와 GRPO의 차이를 학부생에게 설명하라.”

Hard Rule

명확하게 확인할 수 있는 필수 조건

Principle

정성적인 평가 기준

#	Rubric 항목	유형
1	두 방법의 Advantage 계산 방식을 비교한다	**Hard Rule**
2	PPO의 Clipping을 설명한다	**Hard Rule**
3	GRPO의 Group-relative 평가를 설명한다	**Hard Rule**
4	설명이 명확하고 일관적이다	**Principle**
5	근거 없이 성능의 우열을 단정하지 않는다	**Principle**

Generating Rubrics and Avoiding Reward Hacking

Rubric도 완벽한 보상은 아니다

Prompt마다 AI로 Rubric을 자동 생성하고, 기준별 점수를 합쳐 보상을 만든다.

예) 열역학 제1법칙에 대한 설명을 평가하는 Rubric을 작성한다면

```
[
  {
    "title": "Energy Conservation",
    "description": "Essential: Explains conservation of energy.",
    "weight": 5
  },
  {
    "title": "Equation Meaning",
    "description": "Important: Explains heat, work, and energy terms.",
    "weight": 4
  },
  {
    "title": "Sign Convention",
    "description": "Pitfall: Uses inconsistent signs for heat and work.",
    "weight": -2
  }
]
```

잠재적인 문제

누락
Rubric이 중요한 평가 요소를 빠뜨린다

오적용
Judge가 Rubric을 잘못 적용한다

과적합
실제 품질보다 Rubric 점수 자체에 맞춘다

→ **Reward Hacking 점검과 독립적인 평가 필요**